

# Clase 1

## Inteligencia Artificial

Es la inteligencia llevada a cabo por máquinas. Tiene 2 **ramas**

- **Deductiva (Lógica):** Sistemas Expertos
- **Inductiva (Ejemplos):** Redes Neuronales y Técnicas de Optimización.
  - En esta está el Aprendizaje Automático.


El **Aprendizaje Automático** es el subconjunto de técnicas que brindan a las computadoras la capacidad de aprender sin haber sido programadas explícitamente.



## Tipos de Aprendizaje

### Aprendizaje Supervisado

Según si la respuesta a predecir es **discreta o continua** se trata de un problema de **clasificación** o de **regresión** respectivamente.




Con este Aprendizaje podemos dar una **predicción** de un resultado a futuro a partir de los datos disponibles.

### Aprendizaje No Supervisado

Se centra más en el **Agrupamiento** según los datos propuestos. Podemos brindar con este Aprendizaje una **segmentación** de los datos en subgrupos con características similares.


## Redes Neuronales

Buscan emular el comportamiento del cerebro humano.



- Las entradas  $x_i$  representan las **señales/entradas** de información que debe de ser numérica.
- Los  $w_i$  son los **pesos**, estos son numéricos y representan el conocimiento real. Varían su valor en el aprendizaje, buscamos que estos se estabilicen.
- $\theta$  es la **función umbral** que la neurona tiene que pasar para activarse.
- $y$  es la **respuesta** que da la neurona.

Las neuronas se juntan formando una estructura de este estilo:



## Tipos de Redes Neuronales

- Para el **análisis de imágenes** se presentan las **Redes Neuronales Convolucionales**
- También existen redes neuronales que generan datos, tenemos:
  - **Redes Generativas Adversarias (GAN)**: Generan nuevos datos en situaciones en que éstos son limitados.

- **Autoencoders Variacionales (VAE):** Tienen por objetivo reconstruir los datos de entrada. Mejores que las GAN en la generación de caras.

## Análisis de los datos disponibles

### Tipos de Variables

Tenemos las **Cuantitativas o Numéricas:**

- **Discretas:** Cantidad de empleados, de alumnos, etc. Números enteros por así decirlo.
- **Continuas:** Sueldos, metros cuadrados, beneficios, etc. Números flotantes por así decirlo.

También están las **Cualitativas o Categóricas:**

- **Nominales:** Nombran al objeto al que se refieren sin poder establecer un orden, por ejemplo estado civil, raza, idioma, género, etc.
- **Ordinales:** Se puede establecer un orden entre sus valores, por ejemplo alto, mediano, bajo, etc.

### Descripciones estadísticas

Identifican propiedades de los datos y destacan qué valores deben tratarse como ruido o valores atípicos.

### Medidas de Tendencia Central

#### Media/Promedio

Es el promedio de los valores del atributo, dicho atributo debe de ser numérico. Nosotros la truncamos.

$$\bar{X} = \frac{\sum_{i=1}^N x_i}{N}$$

*N es la cantidad de valores a promediar*

Con **Numpy** podemos sacar la Media de una Vector de 1D haciendo lo siguiente:

```
import numpy as np

vector = np.array([1, 2, 3, 4])
media = vector.mean() # 2.5
```

#### Mediana

Es literalmente el valor del medio, divide a los valores del atributo en dos partes iguales. Los valores tienen que estar ordenados para poder obtenerla.

Si la cantidad de datos es **impar**, es el valor del medio.

$$\tilde{X} = x_{(N+1)/2}$$

Si la cantidad de datos es **par**, es el promedio de los 2 valores centrales.

$$\tilde{X} = \frac{x_{N/2} + x_{(N+1)/2}}{2}$$

Con **Numpy** la podemos calcular así:

```
import numpy as np

# Vector con cantidad impar
vector_impar = np.array([1, 3, 5])
print(np.median(vector_impar)) # 3

# Vector con cantidad par
vector_par = np.array([1, 3, 5, 7])
print(np.median(vector_par)) # (3 + 5)/2 = 4.0
```

También puede calcularse sobre **atributos ordinales** que estén ordenados. En tal caso, el resultado será o bien *el valor que divide al conjunto en dos partes iguales* o bien se dirá que *“la mediana está entre los valores ...”*.

## Moda

Es el valor que aparece con mayor frecuencia. Por lo tanto, puede determinarse para atributos **cualitativos y cuantitativos**.

Es posible que la mayor frecuencia corresponda a **varios valores diferentes**, lo que da lugar a más de una MODA (unimodal, bimodal, trimodal, etc.).

Un conjunto de datos con más de una moda se considera **multimodal**. Si cada valor de los datos tiene solo una ocurrencia, entonces **no hay moda**.

Podemos calcular la Moda de varias formas, se puede usar **Numpy + SciPy**, o **Pandas**

```
import numpy as np
from scipy import stats
import pandas as pd

vector = np.array([1, 2, 2, 3, 3, 4, 4, 4, 5])
moda = stats.mode(vector)
```

```
moda.mode[0] # valor de la moda
moda.count[0] # cuantas veces aparece

nuevo_vector = pd.Series([1, 2, 2, 3, 3, 4, 4, 4, 5])
nuevo_vector.mode() #valor de la moda
```

## Rango Medio

Puede utilizarse para evaluar la tendencia central de un conjunto de datos numéricos. Es la media/promedio de los valores máximo y mínimo del conjunto.

$$\text{rango medio} = \frac{\text{maximo} + \text{minimo}}{2}$$

Con **Numpy** lo podemos calcular así:

```
import numpy as np

vector = np.array([1, 2, 3, 4])
rango_medio = (vector.max() - vector.min()) / 2
```

## Medidas de Dispersión

### Varianza y Desviación standard

Mide la dispersión de los datos con respecto a la media.

Valores **bajos** indican que las observaciones de los datos tienden a estar *muy cerca de la media*, mientras que valores **altos** indican que los datos *están muy dispersos*.

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 = \left( \frac{1}{N} \sum_{i=1}^N x_i^2 \right) - \bar{x}^2$$

La **desviación standard** es la raíz cuadrada de la varianza.

Con **Numpy** las calculamos así:

```
import numpy as np

vector = np.array([1, 2, 3, 4])
varianza = vector.var()
desviacion = vector.std()
```

## Rango

El rango de un conjunto de valores numéricos es la **diferencia** entre los valores **máximo** y **mínimo** de dicho conjunto.

## Cuantiles, Cuartiles y Percentiles

Los **cuantiles** son valores que dividen un conjunto numérico **ordenado** en **partes iguales**. Es decir que determinan **intervalos** que comprenden el mismo número de valores. Los más usados son:

- **Cuartiles**: Dividen en 4 partes.
- **Deciles**: Dividen en 10 partes.
- **Centiles o Percentiles**: Dividen en 100 partes.

El **percentil** en estadística nos indica, una vez ordenados los datos de menor a mayor, el valor de la variable por debajo del cual se encuentra un porcentaje dado de observaciones en un grupo.

Se representan como  $Q_1, Q_2, Q_3$ , tomando a  $N$  como la cantidad de valores:

- $Q_1 = (N + 1)/4$
- El 2do, es decir,  **$Q_2$  coincide con la MEDIANA**
- $Q_3 = 3(N + 1)/4$

Si no hay parte decimal en la posición, se toma directamente el **elemento**, es decir, justo nos quedó un número entero.

Si la **posición** corresponde a un **número con parte decimal** entre el elemento  $i$  y el  $i + 1$ , se determina un **factor** realizando una interpolación lineal. El cuartil será:

$$Q = X_i + (X_{i+1} - X_i) \cdot \text{factor}$$

## Cálculo del Factor

Para calcular el factor primero tenemos que saber el valor de la **Frecuencia Acumulada Relativa** de las posiciones que se involucran según el cálculo que nos dio el primer cálculo del cuartil, el cálculo de la **frecuencia acumulada relativa** se define como:

$$F_i = \frac{i + 1}{N - 1}$$

Una vez tenemos los valores de las 2 **frecuencias acumuladas relativas** que se van a involucrar en el cálculo de nuestro **factor** ya podemos realizar correctamente el cálculo de la siguiente manera:

$$factor = \frac{\text{porcentaje que equivale el cuartil} - F_i}{F_{i+1} - F_i}$$

Tener en cuenta que el **porcentaje que equivale el cuartil** varía según cuál estemos calculando, por ejemplo,  $Q1 = 0.25$  pero  $Q3 = 0.75$ .

### Rango Intercuartil

Es la distancia que hay entre  $Q1$  y  $Q3$ , esta distancia es una medida sencilla de dispersión que da el rango cubierto por la mitad de los datos.

Se calcula como:  $Q3 - Q1$

## Gráficos

### Diagrama de Barras


Sirve para mostrar **comparaciones** entre categorías, es mejor usarlo cuando se tienen **datos cualitativos o discretos**. Por ejemplo, mostrar la cantidad de estudiantes en cada facultad.

### Diagrama de Torta

Sirve para ver la **proporción** que representa cada categoría respecto al total, es mejor usarlo cuando queremos resaltar la **participación porcentual** de cada grupo.

### Histograma

Sirve para ver la **distribución de frecuencias** de datos continuos, es mejor usarlo cuando se quiere ver **cómo se distribuyen los datos** (de forma simétrica, sesgada, normal, etc.)




- La **Media** nos representa el **centro de gravedad de los datos**, si la distribución de los datos fuera **simétrica**, la media va a estar **cerca del centro**, si está **desplazada** a un lado (es este caso), indica una **asimetría**.
- La **Desviación Standard** mide cuánto se dispersan los datos respecto a la media hacia la izquierda y derecha.

- Los **Mínimos y Máximos** son los valores más extremos observados, nos dicen el rango total de valores observados.
- El **Rango** nos dice qué tan amplia es la distribución, se interpreta como la anchura total del eje X que ocupan las barras.

## Diagrama de Caja

Sirve para ver los **cuartiles, la mediana y los valores atípicos**, es mejor usarlo cuando se quiere analizar la **dispersión y simetría de los datos**, o comparar distribuciones entre grupos.

- Consideramos **valores atípicos leves** a los que se encuentran a:  $1.5 \cdot RIC$  ( $RIC$  Rango Intercuartil) más allá de los límites de la caja hacia la izquierda o derecha.
- Consideramos **valores atípicos extremos** a los que se encuentran a:  $3 \cdot RIC$  más allá de los límites de la caja hacia la izquierda o derecha.



- Los **límites teóricos** son los que se calculan en la imagen como  $Lim. Inf$  y  $Lim. Sup$ , el rango comprendido por estos, es decir,  $[Lim. Inf, LimSup]$  son todos los **valores no atípicos**.
- Los **bigotes** en el gráfico indican el rango de los valores de la muestra comprendidos en el intervalo.
  - El **bigote superior** es el valor más grande del conjunto de datos que sea  $\leq Lim. Sup$ .
  - El **bigote inferior** es el valor más pequeño del conjunto de datos que sea  $\geq Lim. Inf$ .

## Diagrama de Dispersión

Sirve para ver la **relación** entre 2 variables numéricas, es mejor usarlo para analizar **correlaciones** o **tendencias** entre dos variables.

### Relación entre atributos numéricos

Cuando hagamos un modelo de IA nos interesa saber si dos atributos numéricos se encuentran **linealmente relacionados** o no. Para ver eso se usa el **coeficiente de correlación lineal**.



Dados dos atributos  $X$  e  $Y$ , el **coeficiente de correlación lineal** entre ellos se calcula de esta forma:

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sigma_x \cdot \sigma_y}$$

Teniendo en cuenta que:

- $Cov(X, Y)$  es la **covarianza** entre  $X$  e  $Y$ 
  - Este valor nos indica el grado de variación conjunta de dos variables aleatorias respecto a sus medidas. Puede ser Positiva, Negativa o Cercana a cero.
- $\sigma_x$  y  $\sigma_y$  son los **desvíos** de cada variable.

$$Cov(X, Y) = \left[ \sum_{i=1}^N (x_i - \mu_X)(y_i - \mu_Y) \right] / N$$
$$\sigma_X = \sqrt{\left[ \sum_{i=1}^N (x_i - \mu_X)^2 \right] / N}$$

### Interpretación del Coeficiente

- Si  $0.5 \leq |Corr(A, B)| < 0.8$  se dice que  $A$  y  $B$  tienen una **correlación lineal débil**.
- Si  $|Corr(A, B)| \geq 0.8$  se dice que  $A$  y  $B$  tienen una **correlación lineal fuerte**.
- Si  $|Corr(A, B)| < 0.5$  se dice que  $A$  y  $B$  **no están correlacionados linealmente**. Eso no implica que son independientes.

## Fase de Preparación de los Datos

La **información** que está almacenada siempre va a presentar:

- Datos faltantes.
- Valores extremos.
- Inconsistencias.
- Ruido


Nosotros tenemos que detectar estas anomalías/fallas para hacer una **Limpieza** y una **Transformación** de la información.

## Integración


Es un proceso que se realiza durante la **recopilación de datos** y, si se realiza un almacén de datos, durante el **proceso de carga**, puede, en muchos casos, **detectar y solucionar** problemas de datos no resueltos durante la integración, como los **valores anómalos y faltantes**.

## Problemas que se pueden dar

1. El primer problema a la hora de realizar una **integración** de distintas fuentes de datos es **identificar los objetos**, es decir, conseguir que datos sobre el mismo objeto se unifiquen y datos de diferentes objetos permanezcan separados. Este problema se conoce como **el problema del esclarecimiento de la identidad**. Pueden pasar 2 errores:
  - Dos o más objetos que son **diferentes** terminan unificados.
  - Dos o más fuentes de objetos **iguales** terminan separadas.
    - Este es el más común.
2. Cuando se integran las fuentes de información se realiza un **proceso de descomposición de claves** para entender mejor la composición de las mismas, si las claves están mal diseñadas pueden entrañar información no normalizada.



3. Cuando se integran (correctamente) dos fuentes diferentes de datos de distintos objetos suele suceder que puedan aparecer **datos faltantes** (el dato se registra en una fuente pero no en la otra) o **datos inconsistentes** (el dato es diferente en una fuente y otra).
4. La **integración de formatos diferentes**, que se produce si tenemos codificaciones diferentes (casado / matrimonio), idiomas diferentes, medidas diferentes, etc. requiere de una unificación.



## Reconocimiento

Cuando tenemos integrados todos los datos lo primero que podemos realizar es un **resumen de las características** (o informe de estado) **de atributos** (ya sea tabla a tabla o para toda la base o almacén de datos).

En este tipo de tablas se muestran las características generales de los atributos (medias, mínimos, máximos, posibles valores).

| Atributo         | Tabla    | Tipo     | # total | # nulos | # dists | Media   | Desv.e. | Moda       | Min         | Max         |
|------------------|----------|----------|---------|---------|---------|---------|---------|------------|-------------|-------------|
| Código postal    | Ciente   | Nominal  | 10320   | 150     | 1672    | -       | -       | "46003"    | "01001"     | "50312"     |
| Sexo             | Ciente   | Nominal  | 10320   | 23      | 6       | -       | -       | "V"        | "E"         | "M"         |
| Estado civil     | Ciente   | Nominal  | 10320   | 317     | 8       | -       | -       | Casado     | "Casado"    | "Viudo"     |
| Edad             | Ciente   | Numérico | 10320   | 4       | 66      | 42,3    | 12,5    | 37         | 18          | 87          |
| Total póliza p/a | Póliza   | Numérico | 17523   | 1325    | 142     | 737,24€ | 327€    | 680€       | 375€        | 6200€       |
| Asegurados       | Póliza   | Numérico | 17523   | 0       | 7       | 1,31    | 0,25    | 1          | 0           | 10          |
| Matrícula        | Vehículo | Nominal  | 16324   | 0       | 16324   | -       | -       | -          | "A-0003-BF" | "Z-9835-AF" |
| Modelo           | Vehículo | Nominal  | 16324   | 1321    | 2429    | -       | -       | "D. Astra" | "Audi A3"   | "VW Polo"   |
| ...              | ...      | ...      | ...     | ...     | ...     | ...     | ...     | ...        | ...         | ...         |

Tabla 4.1. Tabla resumen de atributos.

Una vez tenemos esta información, podemos realizar más que nada **Histogramas, Diagramas de Caja o Diagramas de Dispersión** para poder reconocer y comprender más las anomalías que se presentan.

## Valores Faltantes

Hay que estar atentos a que un **valor faltante** no necesariamente es un valor que está representado como **NULO**, puede pasar por ejemplo que en una columna que sea "dirección" nos digan "no tiene", eso se vuelve un valor faltante que **no es NULO**.

Para estos **valores** ya sean nulos o no podemos hacer muchas cosas:

- Ignorarlos.
- Rellenarlos manualmente.
- Usar una constante global para rellenarlos.
- Usar el valor de la **Media** u otra medida de centralidad para rellenarlos.
- Usar el valor de la **Media** u otra medida de centralidad de los objetos que pertenecen la misma clase.
- Usar alguna técnica de **Aprendizaje Automático** para calcular el valor más probable.

## Problemas que surgen con estas medidas

Si sustituimos un dato faltante por un dato estimado, hemos de tener en cuenta que:

1. **Perdemos información**, ya que ya no se sabe que el dato era faltante y,
2. **Inventamos información**, con los riesgos que pueda tener de que sea errónea.

## Solución

Creamos un **nuevo atributo lógico (booleano)** indicando si el atributo original **era nulo o no**. Esto permite al proceso y al método de minería de datos, si son bastante perspicaces, saber que el dato era **faltante** y, por tanto, que el valor hay que tomarlo con **cautela**.

En el caso en el que el atributo original sea **nominal** no es necesario crear un nuevo atributo, basta con **añadir un valor adicional**, denominado "faltante".

## Transformación de Atributos

La **transformación de datos** engloba, en realidad, cualquier proceso que modifique la forma de los datos. Prácticamente todos los procesos de preparación de datos entrañan algún tipo de transformación.

### Discretización

Algunos algoritmos de minería de datos sólo operan con atributos cualitativos. La discretización **convierte los atributos numéricos en ordinales ordenados** que se representan con un intervalo.

Ayuda a que los **valores anómalos** caigan en alguno de los extremos sin problema.


Ejemplo: La edad de la persona en categorías:  $[0, 12]$  niño,  $(12 - 21)$  joven,  $[21, 65]$  adulto y  $> 65$  anciano.

Se puede discretizar en un **número fijo de intervalos**, el **ancho** del intervalo se calcula:

- Dividiendo el rango en partes iguales.
- Dividiendo la cantidad de ejemplos en partes iguales (igual frecuencia).
- Indicando los límites de cada intervalo en forma manual.


### Discretización por Rangos

El objetivo es dividir el **rango del atributo** (intervalo entre el máximo y el mínimo) en una cierta cantidad  $k$  de **partes iguales**.



### Discretización por Frecuencia

El objetivo es dividir los **valores del atributo numérico** en  $k$  partes con la **misma cantidad de valores** en cada una de ellas. El atributo debe tener al menos  $k$  **valores diferentes**.



## Numerización

Es el **proceso contrario a la discretización**. Convierte atributos **cualitativos en numéricos**.

Para los **nominales** suele utilizarse una representación binaria y para los **ordinales** suele utilizarse una representación entera.

- Si se numeran en forma correlativa los valores de un **atributo nominal** se agrega un **orden** que originalmente **no está presente** en la información disponible.

## Numerización Binaria (dummy)

Reemplaza al **atributo nominal** por tantos **atributos numéricos binarios** como **valores distintos** pueda tomar.

Las denominaciones de estos nuevos atributos surgen de igualar el **nombre original** con cada uno de los **posibles valores**. Para un mismo ejemplo sólo uno de estos nuevos atributos tendrá valor 1 y el resto 0.

## Normalización

Permite expresar los **valores de los atributos** sin utilizar las unidades de medida originales facilitando su comparación y uso conjunto.

Si bien se aplica según el modelo a construir, la más común es la **normalización lineal uniforme**:

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

- Es muy sensible a los valores outliers.
- Si recortamos los extremos obtenemos valor negativos y/o mayores a 1.

Si los datos tienen una **distribución normal**, podemos **tipificar**:

$$X' = \frac{X - \text{media}(X)}{\text{desviacion}(X)}$$

- De esta forma los datos se distribuyen normalmente alrededor de 0 con desviación 1.